TRANSFORMAÇÕES

Razões para transformar os dados antes das análises:

1 – Tornar comparáveis descritores medidos em diferentes unidades

Isso é feito através da padronização (Standardization), que significa tornar padrão (igual).

Padronização: subtraia a média da variável de todos os valores (ou seja, centrar a variável). Divida o resultado pelo desvio padrão da variável (escalonar a variável). Ou seja:

$$y'_i = \frac{y_i - \bar{y}}{S_y}$$

Que resulta numa variável com média zero e variância igual a unidade (portanto, desvio padrão também = 1).

As variáveis padronizadas podem ser diretamente comparáveis, pois elas agora não possuem dimensão e são expressas em unidades de desvio padrão.

2 – Normalizar os dados e estabilizar a sua variância

Normalização significa tornar normal, ou seja, tornar a distribuição de frequências dos valores parecido com a distribuição normal ou, pelo menos, torná-la simétrica.

A normalidade é um pressuposto de uma série de testes estatísticos uni- e multivariados. A normalidade plena não é necessária, mas a performance dos métodos é melhorada se os dados não são muito assimétricos.

A normalização pode ser feita de diferentes maneiras, que requerem o exame da distribuição de frequência dos dados. Em muitos casos, dados ecológicos são assimétricos à direita, pois as espécies são presentes em poucas unidades e ausentes na maioria.

A transformação normalizadora geralmente tem a propriedade de estabilizar as variâncias, ou seja, tornar os dados homocedásticos para cada grupo (com a mesma variância), pressuposto para qualquer análise paramétrica.

2.1. Raiz quadrada

É a menos drástica das transformações, usada quando temos a distribuição de Poisson , normalmente dados de contagem, como abundância de uma espécies ou riqueza de espécies.

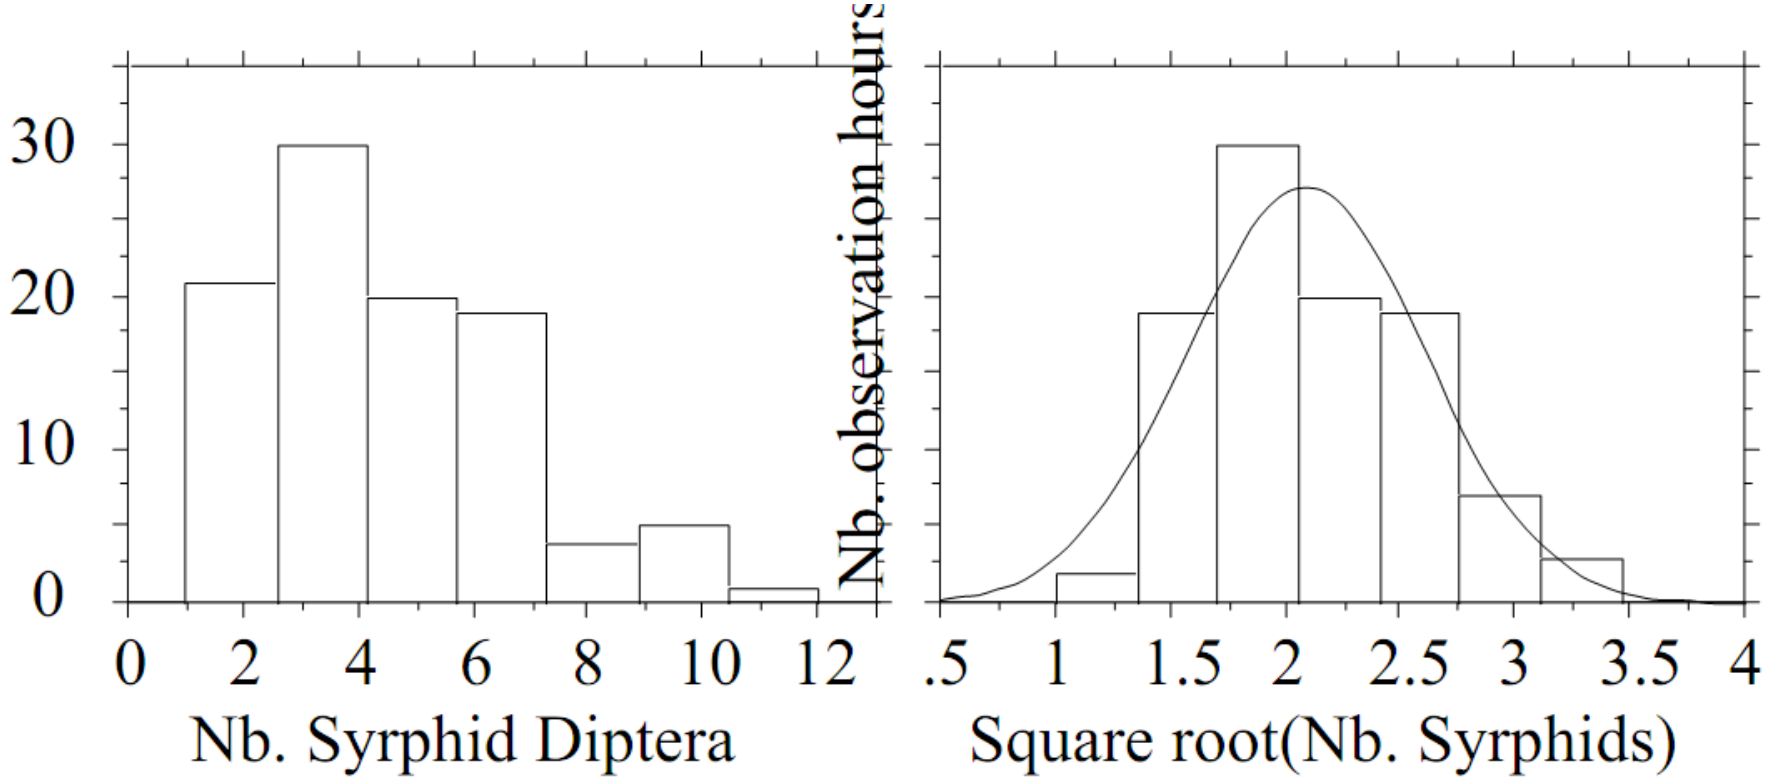

Efeito da transformação pela raiz quadrada para dados de abundância.

2.2. Transformação logarítmica

Aplicada a dados que apresentam distribuição log-normal. A base do logaritmo não é importante, mas a mais usada é a base 10 e a base natural. Uma constante deve ser adicionada a cada valor para torná-lo positiva, caso necessário.

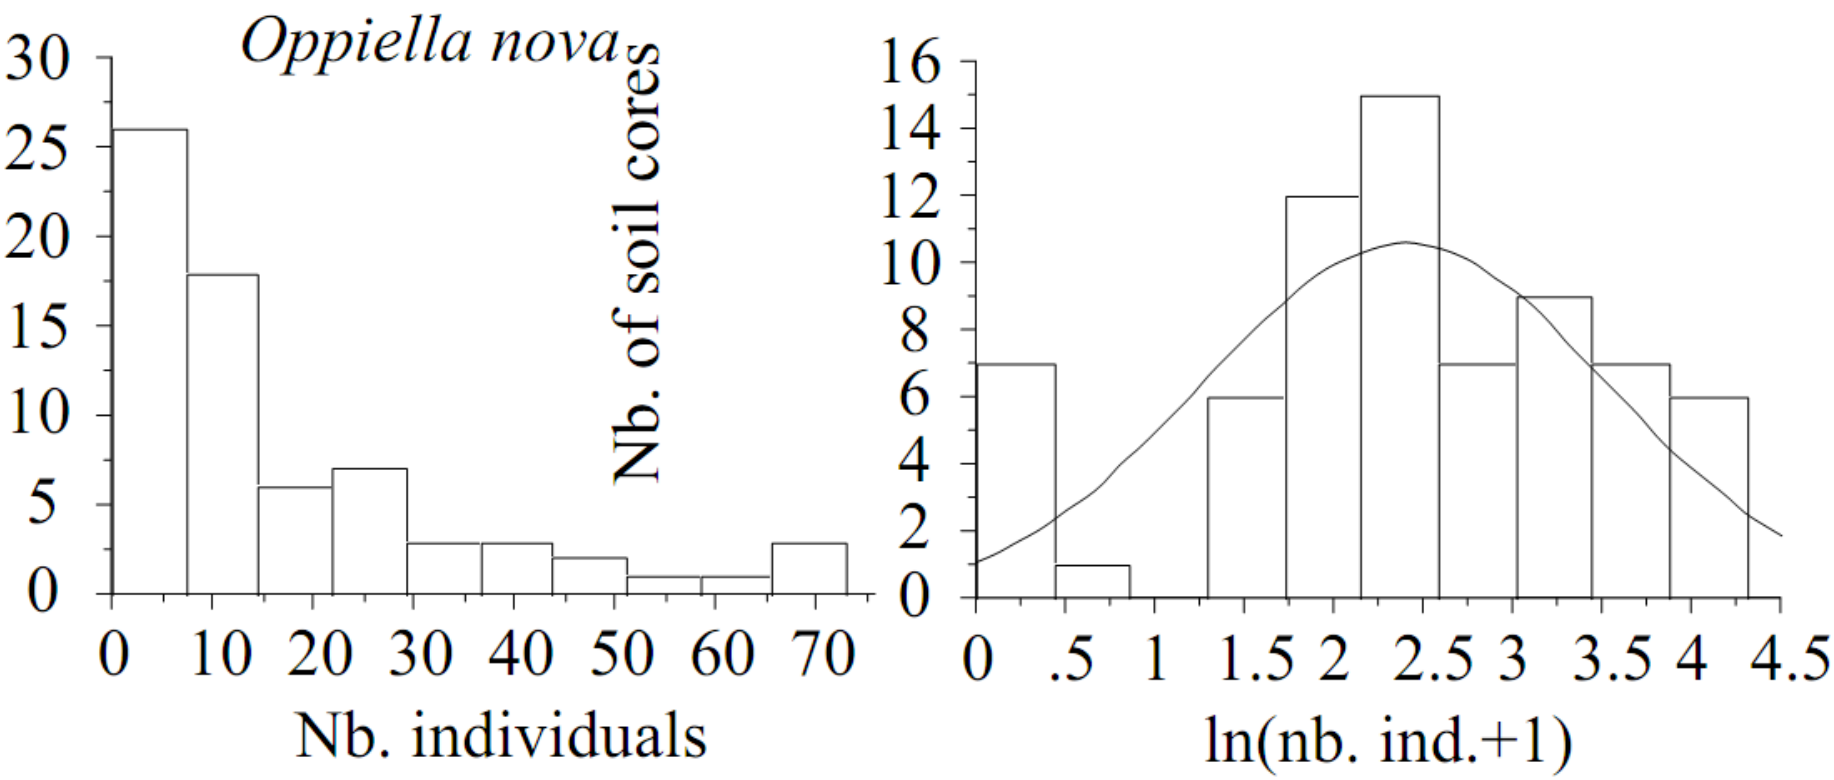

Efeito da transformação logarítmica para dados de abundância.

2.3. Transformação pelo arco-seno

É apropriada para percentagens ou proporções, que geralmente são platicúrticas. Os resultados analíticos baseados nesta transformação podem ser difíceis de interpretar.

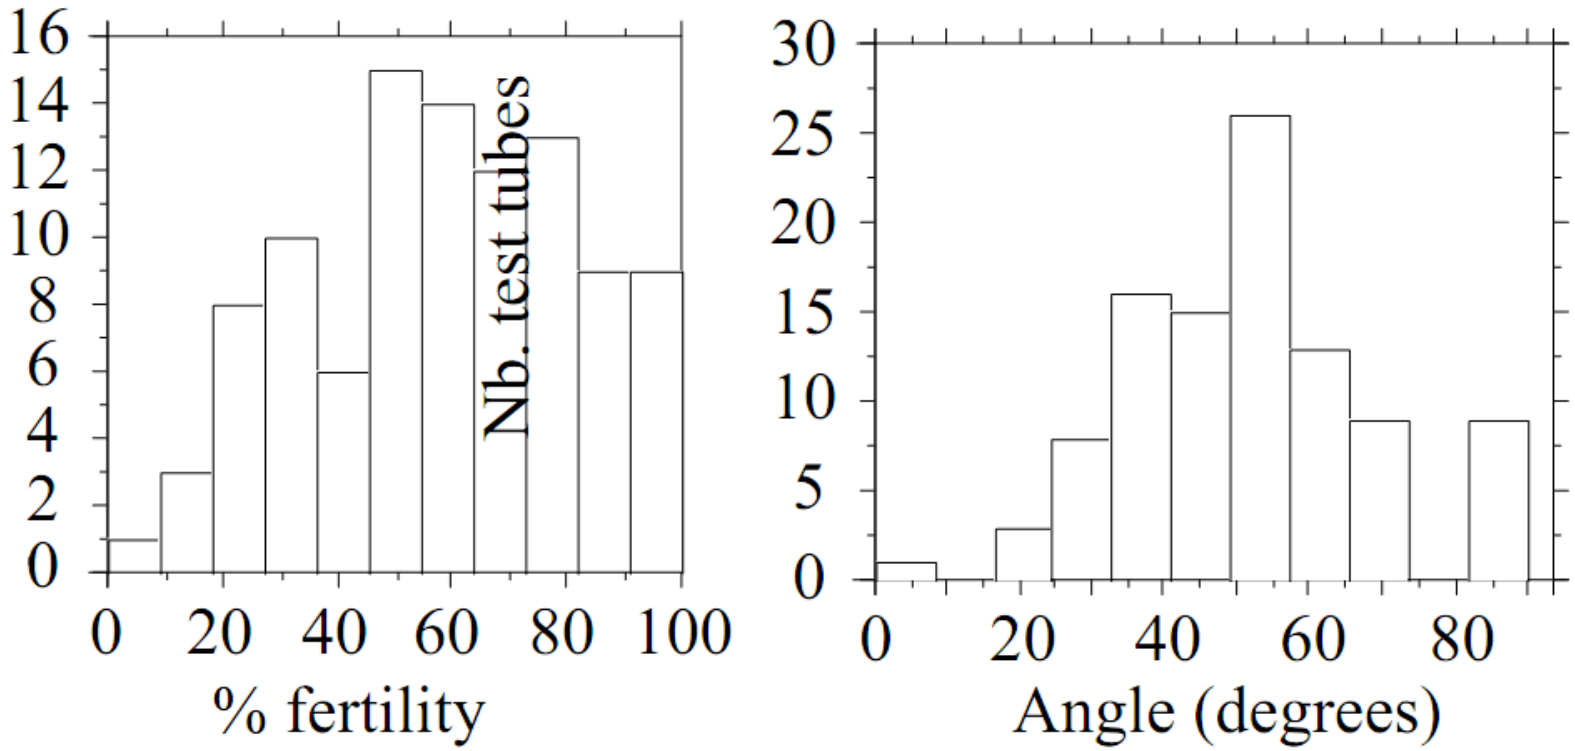

Efeito da transformação por arco-seno para dados de proporção.

2.4. Transformação de Box-Cox

Tukey introduziu a chamada *Power trasformation*, que consiste em encontrar o melhor valor de lambda para a função:

$$y'_i = y^{\lambda}$$

Box-Cox escalonaram o valor de y e incluíram a possibilidade de lambda ser igual a zero (caso contrário, todos os valores seriam igual a 1).

$$y'_i = \frac{y_i^{\lambda} - 1}{\lambda} \; para \; \lambda \neq 0$$

$$y'_i = \ln(y_i) \;\; para \; \lambda = 0$$

Quando não houver nenhuma razão *a priori* para usar uma das transformações citadas anteriormente, usa-se a transformação de Box-Cox, que empiricamente (iterativamente) estima o expoente lambda mais apropriado para a função acima.

Dependendo de lambda, a transformação de Box-Cox incorpora muitas outras transformações tradicionais:

Lambda	Resultado
λ=1,00	Produz resultado igual aos dados originais
λ=0,50	Transformação por raiz quadrada
λ=0,33	Transformação por raiz cúbica
λ=0,25	Transformação por raiz a quarta
λ=0,00	Transformação logarítmica
λ=-0,50	Transformação inversa por raiz quadrada (1/raiz)
λ=-1,00	Transformação inversa

Uma maneira simplificada de realizar a transformação de Box-Cox é através da estimativa da regressão entre média e desvio padrão.

Como decidir se usa $x^{0,5}$ ou $x^{0,25}$?

Faça uma regressão entre o Log das médias das estações pelo Log do desvio padrão das estações.

#1	#2	#3		#1	#2	#3
1	0	1	Média	2,75	2,25	1,75
4	2	3	D.P.	2,76	2,62	0,95
6	6	2				
0	1	1				

De onde vem a regressão:

Log(Média) = a + b * Log(DP)

Se b <= 0,5 então $x^{0,5}$

Se b >= 0,75 então $x^{0,25}$

3. Linearizar as relações entre variáveis

O coeficiente de correlação linear de Pearson detecta apenas relações lineares. Então, caso uma relação entre duas variáveis seja monotônica (só cresce ou só decresce) e não-linear, então é possível aplicar uma transformação para tornar a relação linear. Se uma variável dependente é uma função exponencial da variável independente, então a variável dependente pode ser transformada. Por exemplo, seja a função de crescimento Mauthusiano:

$$N_t = N_0 e^{rt}$$

Que pode ser linearizada aplicando log natural:

$$\ln(N_t) = \ln(N_0) + rt$$

3. Codificação de variáveis semi-quantitativas (ordinais) em quantitativas

Uma variável é semi-quantitativa ou ordinal quando a precisão na sua medida é insuficiente para fornecer precisão, ainda que exista a possibilidade de estimar a magnitude (maior ou menor). Por exemplo, a abundância de uma espécie é medida apenas em intervalos, codificados desde ausente (0) até muito abundante (5).

4. Codificação binária de variáveis nominais

Variáveis nominais não possuem magnitude, ao contrário das variáveis ordinais. Assim, não é possível estabelecer quem é maior ou menor. No entanto, é possível codificar cada variável nominal como presente (1) ou ausente (0).