ESTATÍSTICA

Termo vem de *status* → Aspectos de um país (tamanho da população, taxas de mortalidade, taxas de desemprego, renda per capita).

Estatística é o conjunto de métodos para a obtenção, organização, resumo, análise e interpretação dos dados.

Estatística descritiva: organizar, analisar, interpretar dados.

Estatística inferencial: Obter respostas de questões específicas com um determinado grau de acerto (teste de hipóteses).

TIPOS DE DADOS

→ **Qualitativos:** Observações não numéricas

- **Nominais**: Refere-se a nomes. Seqüência não é importante. Ex: Nome de pessoas, sexo, estado civil, tipo de sangue, cores de carros.

Quando existem somente dois valores, são chamados dicotômicos ou binários.

- **Ordinais**: Refere-se a ordem. Existe uma escala que pode ser convertida para numérica. Ex: Tipo de lesão (fatal, grave, moderada e leve), estado do mar (tormenta, agitado, mexido, espelhado), atividade de um animal (ativo, movimentos restritos, incapaz, imóvel), zonação de salinidade em um estuário (euhalino, polihalino, mesohalino, oligohalino).

→ **Quantitativos:** Observações numa escala numérica

- **Discretos**: Assumem somente números inteiros positivos (0,1,2,3...). Resultam de contagens e nenhum valor intermediário é possível. Ex: quantidade de filhos de uma família, quantidade de peças defeituosas, quantidade de desempregados no país, abundância de determinada espécie num local.

- **Contínuos**: Assumem qualquer valor do conjunto de números reais. Normalmente envolve precisão. Ex: alturas e pesos de pessoas, renda familiar, tempo de gestação, consumo de energia elétrica, biomassa de uma planta num local.

PROPRIEDADES DOS DIFERENTES TIPOS DE DADOS

	Seqüência	**Magnitude**	**Ordem**	**Permite cálculos aritméticos**	**Restrito a números inteiros**
Nominais	Não	Não	Não	Não	N.A.
Ordinais	Sim	Não	Sim	Alguns	Sim
Discretos	Sim	Sim	Sim	Sim	Sim
Contínuos	Sim	Sim	Sim	Sim	Não

EXEMPLO DE DISTRIBUIÇÕES DE FREQUÊNCIA

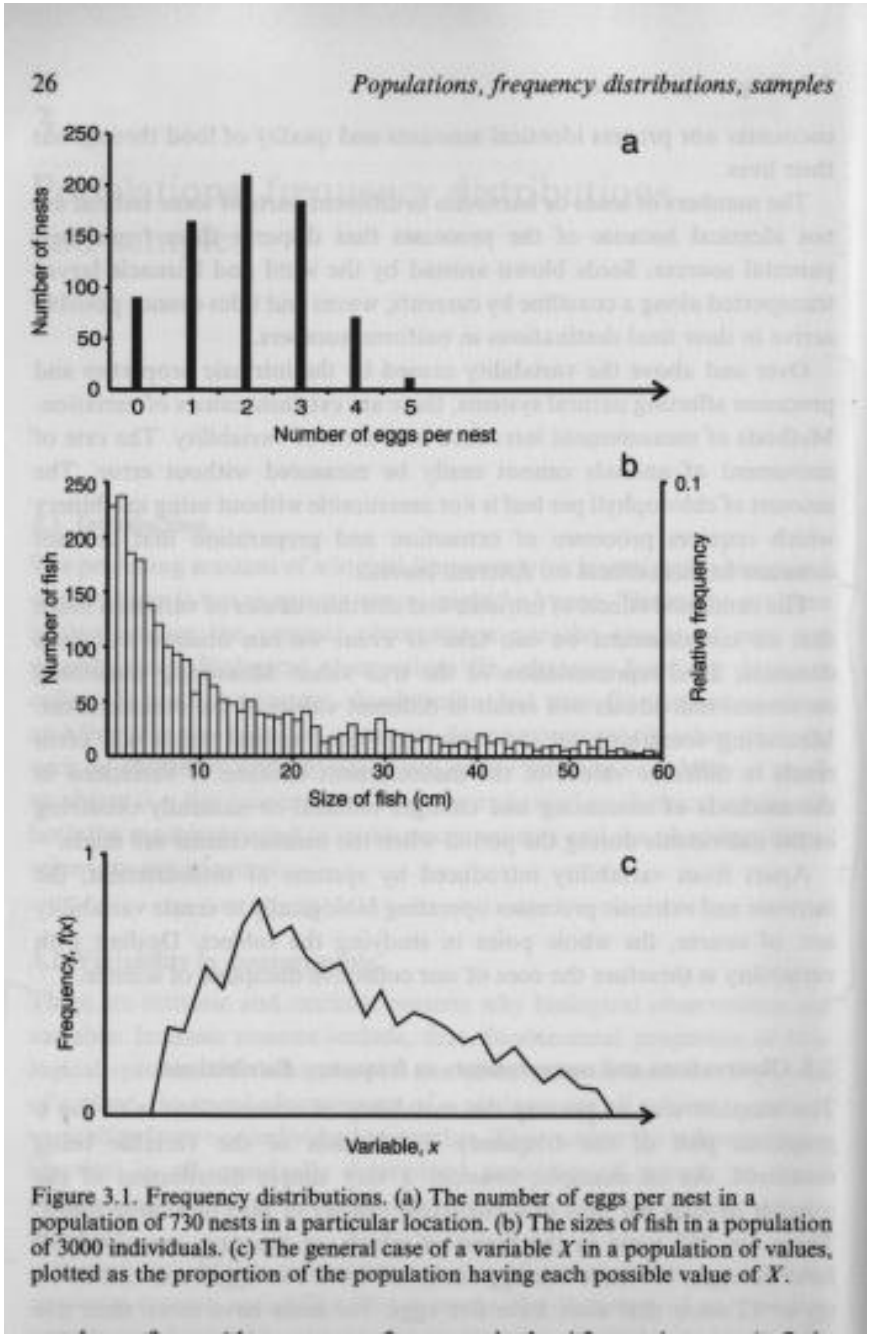

Figure 3.1. Frequency distributions. (a) The number of eggs per nest in a population of 730 nests in a particular location. (b) The sizes of fish in a population of 3000 individuals. (c) The general case of a variable X in a population of values, plotted as the proportion of the population having each possible value of X.

DISTRIBUIÇÃO NORMAL

Os dados abaixo são as medições do tamanho do espinho tibial de 50 aranhas

TABLE 3.1 Ordered measurements of tibial spines of 50 linyphiid spiders (millimeters)

0.155	0.207	0.219	0.228	0.241	0.249	0.263	0.276	0.292	0.307
0.184	0.208	0.219	0.228	0.243	0.250	0.268	0.277	0.292	0.308
0.199	0.212	0.221	0.229	0.247	0.251	0.270	0.280	0.296	0.328
0.202	0.212	0.223	0.235	0.247	0.253	0.274	0.286	0.301	0.329
0.206	0.215	0.226	0.238	0.248	0.258	0.275	0.289	0.306	0.368

This simulated dataset is used throughout this chapter to illustrate measures of summary statistics and probability distributions. Although raw data of this sort form the basis for all of our calculations in statistics, the raw data are rarely published because they are too extensive and too difficult to comprehend. Summary statistics, if they are properly used, concisely communicate and summarize patterns in raw data without enumerating each individual observation.

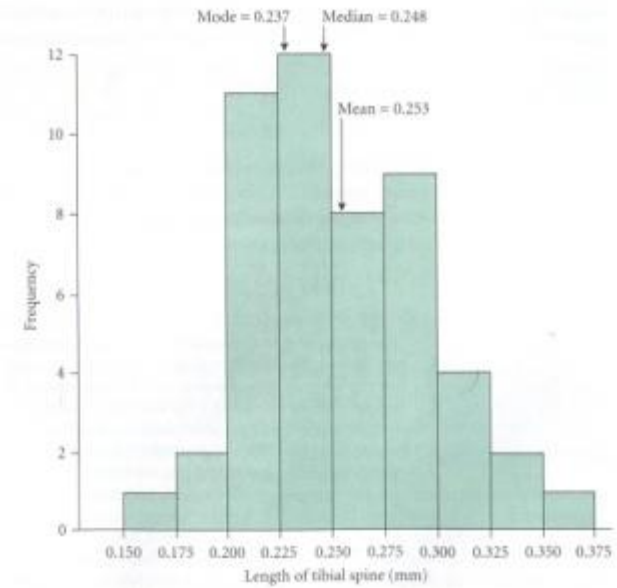

Figure 3.2 Histogram of the tibial spine data from Table 3.1 ($n = 50$) illustrating the arithmetic mean, median, and mode. The mean is the expectation of the data, calculated as the average of the continuous measurements. The median is the midpoint of the ordered set of observations. Half of all observations are larger than the median and half are smaller. The mode is the most frequent observation.

Todas as medições na natureza tendem à distribuição normal.

Base teórica das análises paramétricas (regressão, teste-t, ANOVA, etc).

Propriedades da curva normal para um conjunto de dados

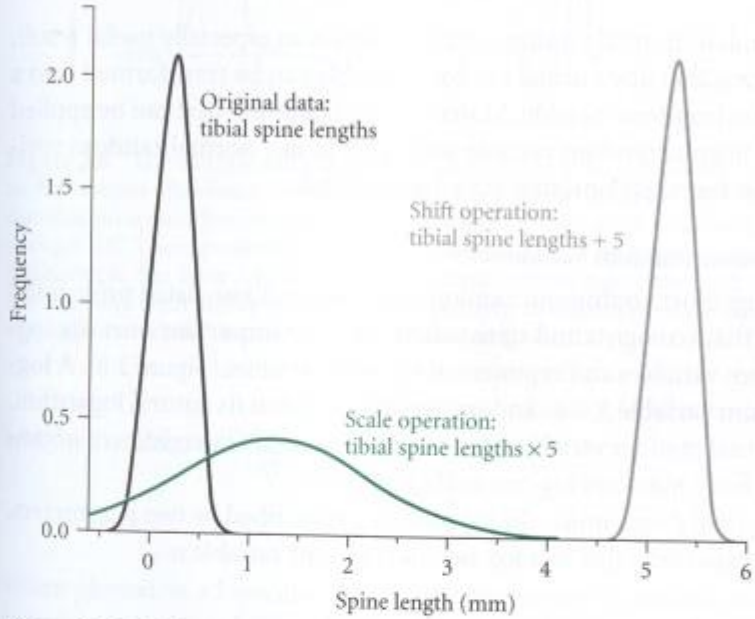

Figure 2.7 Shift and scale operations on a normal distribution. The normal distribution has two convenient algebraic properties. The first is a shift operation: if a constant b is added to a set of measurements with a mean μ, the mean of the new distribution is shifted to $\mu + b$, but the variance is unaffected. The black curve is the normal distribution fit to a set of 200 measurements of spider tibial spine length (Figure 2.6). The gray curve shows the shifted normal distribution after a value of 5 was added to each one of the original observations. The mean has shifted 5 units to the right, but the variance is unaltered. In a scale operation (green curve), multiplying each observation by a constant a causes the mean to be increased by a factor of a, but the variance to be increased by a factor of a^2. This curve is the normal distribution fit to the data after they have been multiplied by 5. The mean is shifted to a value of 5 times the original, and the variance has increased by a factor of $5^2 = 25$.

Teorema do limite central

Qualquer que seja a distribuição da variável de interesse para grande amostras, a distribuição das médias amostrais serão aproximadamente normalmente distribuídas, e tenderão a uma distribuição normal à medida que o tamanho de amostra crescer.

Por quê?

Porque os dados são influenciados normalmente por muitos fatores aleatórios não relacionados entre si. Quase todos os conjuntos dados são resultados de efeitos diferente. A altura das pessoas, por exemplo, é resultado de fatores hereditários, ambientais, nutrição e cuidados médicos

MEDIDAS DE POSIÇÃO E DE TENDÊNCIA CENTRAL

São medidas que resumem o conjunto de dados a um único número.

Não substituem o uso de gráficos e tabelas, pois implica numa redução excessiva e conseqüente perda de informação.

São medidas de posição e de tendência central :

- Média aritmética
- Moda
- Mediana

Medida de posição:

- Separatrizes

MÉDIA ARITMÉTICA ($\overline{X}$)

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$$

A média a partir de uma tabela de frequência:

$$\overline{X} = \frac{1}{n}\sum_{i=1}^{n} X_i f_i$$ onde X_i é o ponto médio.

i	Classe	X_i	Freqüência (f_i)
1	10---20	15	3
2	20---30	25	2
3	30---40	35	4

$$\overline{X} = (15x3) + (25x2) + (35x4)$$

Desvantagens da média aritmética

- Depende de todos os valores da série;
- Muito sujeita a valores extremos (outliers)
- A média pode ser um valor inexistente na série, como a média de filhos de uma família ser 4,5;

PROPRIEDADES DA MÉDIA

1 - O somatório dos desvios em relação à média aritmética é igual a zero

→ Série {1,3,5} $\bar{x} = 3$

Soma dos desvios = (1-3)+(3-3)+(5-3)=0

2 - Se somarmos ou subtrairmos uma constante a cada valor de Xi da série, a média aritmética ficará aumentada ou diminuída desta constante;

3 - Se multiplicarmos ou dividirmos cada variável da série por uma constante, a média aritmética será multiplicada ou dividida por esta constante.

Ex. Seja:

X_i	X_i+2	X_i x 2
5	7	10
3	5	6
2	4	4
1	3	2
4	6	8
$\overline{X} = 3$	$\overline{X} = 5$	$\overline{X} = 6$

MODA (Mo)

Moda é o evento mais freqüente de uma distribuição.
Série {1,1,3,3,3,5,7,7,9} a moda é 3.
Amodal: não existe moda.
Unimodal – possui apenas uma moda. Ex. mostrado acima.
Bimodal – Possui duas modas.
Polimodal – possui três, quatro ou mais modas.

Vantagens da moda:

- Não depende de todos os valores da série

- Não é influenciada por valores extremos (outliers)

- Apresenta existência real dos dados

MEDIANA (Md)

A mediana é o valor central dos valores ordenados de uma série. Ela divide uma série estatística em dois subconjuntos de valores com a mesma quantidade de elementos.

Série {1,3,5,7,9} Md=5 → (n+1)/2
Série {1,3,5,7} Md=4 → média entre n/2 e n/2+1

Vantagens da mediana:

- Não depende de todos os valores da série

- Não é influenciada por valores extremos (outliers)

- A mediana pode ser um valor inexistente na série

POSIÇÃO RELATIVA DA MÉDIA, MEDIANA E MODA

Para uma distribuição com a curva simétrica temos:

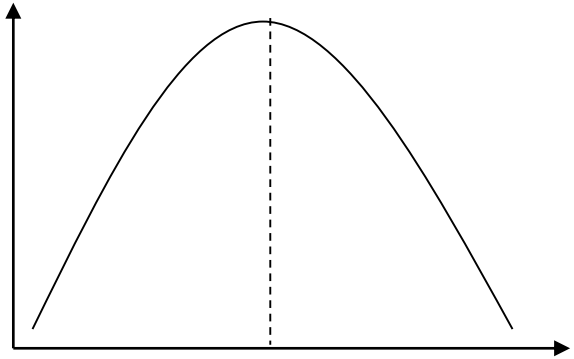

$$\overline{X} = Md = Mo$$

Para uma distribuição com curva assimétrica negativa, temos:

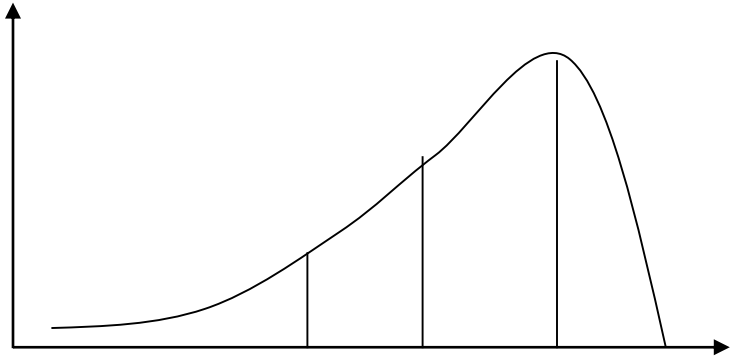

$$\overline{X} < Md < Mo$$

Para uma distribuição com curva assimétrica positiva, temos:

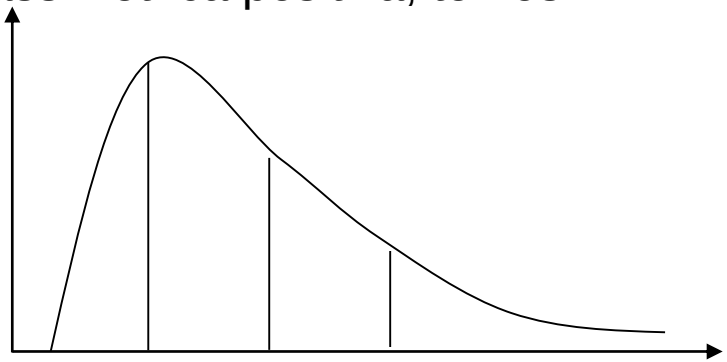

$$Mo < Md < \overline{X}$$

Assimetria será vista em mais detalhes mais adiante.

O QUE USAR: MÉDIA, MODA OU MEDIANA?

→Tipo de dado:
- Para dados nominais, somente a moda pode ser aceita;
- Para dados ordinais, tanto a moda quanto a mediana podem ser usadas;
- Para dados quantitativos a média é adequada;

→Forma da distribuição:
- Em distribuições simétricas se usa a média;
- Em distribuições assimétricas, é preferível a mediana ou a moda;

→Número de modas
- Para as unimodais, utiliza-se qualquer uma das três;
- Para as bi-modais, é preferível usar somente as modas, e ambas as duas.

SEPARATRIZES

São medidas de posição, mas não de tendência central
Enquanto a mediana divide os valores da série em dois, representação 50% dos dados, outras proporções podem ser extraída dos dados.

São elas: Quartis, Decis e Percentis.

Quartil - Divide a série de dados em quatro partes.

Suponha a reta de valores de uma série. Para que os quartis dividam essa série em quatro partes iguais, precisamos da presença apenas de três quartis.

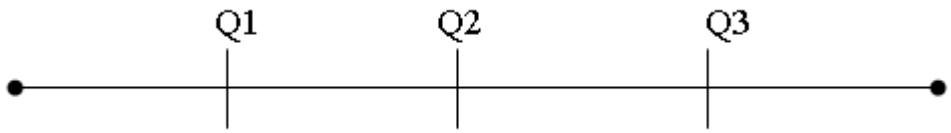

Q1 – Posição de determinada variável de tal maneira que 25% dos dados da série tem valor menor que o seu. E 75% dos dados tem valor superior ao seu.

Q2 – Coincide exatamente com a mediana.

Q3 - Posição de determinada variável de tal maneira que 75% dos dados da série tem valor menor que o seu. E 25% dos dados tem valor superior ao seu.

Exemplo: seja a série
{1,3,3,4,5,6,7,9,10,11,11,15}
Q1=3; Q2=6,5; Q3=10

Decis dividem a série em 10 e percentis dividem a série em 100.

MEDIDAS DE DISPERSÃO OU VARIABILIDADE

A média indica o centro e as medidas de dispersão medem o grau de homogeneidade entre os valores da série.

Seja a série {1,3,5,7,9}

AMPLITUDE TOTAL (AT)

$AT = X_{max} - X_{min}$

AT=9-1=8

Desvantagem: só leva em conta dois valores. Pode ser usada por exemplo para calcular os extremos de temperatura em um só dia.

AMPLITUDE TOTAL INTERQUARTÍLICA (ATi)

É a metade da diferença entre o terceiro e o primeiro quartil.

ATi=(Q3-Q1)/2

ATi=(7-3)/2=2

DESVIO MÉDIO ABSOLUTO (DMA)

Somatório da distância entre cada ponto da série e sua média.

$$DMA = \frac{\sum |Xi - \overline{X}|}{n}$$

Em módulo para não somar zero

DMA=1/5[|1-5|+|3-5|+|5-5|+|7-5|+|9-5|]=1,4

VARIÂNCIA (σ^2)

Transforma todas as diferenças para positivo sem necessidade do módulo, a partir da soma dos quadrados. Mais robusta, porém não está na mesma escala da média.

$$\sigma^2 = \frac{\sum (Xi - \overline{X})^2}{n}$$

$$\sigma^2 = [(-4)^2 + (-2)^2 + (0)^2 + (2)^2 + (4)^2]/5 = 8$$

DESVIO PADRÃO(σ)

O problema da variância é a escala. Como tudo foi elevado ao quadrado, agora retornamos para a mesma escala da média extraindo a raiz quadrada.

$$\sigma = \sqrt{\frac{\sum (Xi - \overline{X})^2}{n}}$$

$$\sigma = \sqrt{8} = 2{,}82$$

Este valor é adequado como medida de variabilidade para qualquer análise estatística.

O desvio padrão da população é representado por σ e o desvio padrão da amostra é dado por S.

$$S = \sqrt{\frac{1}{n-1} \sum (Xi - \overline{X})^2}$$

Propriedades do desvio padrão

- Somando uma constante a todos os valores da série, o desvio padrão não se altera;

- Multiplicando os valores o desvio será igualmente multiplicado.

Efeito da modificação das médias (a) e do desvio padrão (b) na distribuição de freqüência.

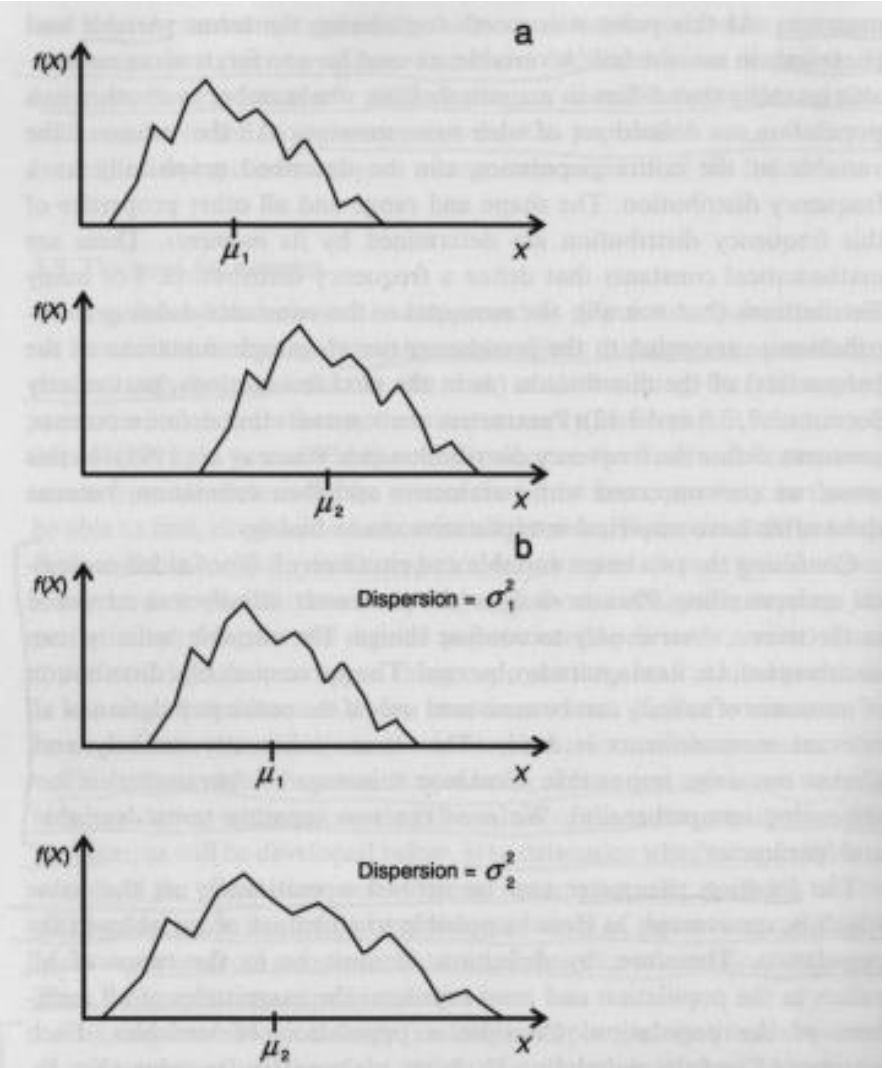

Figure 3.2. Effects of differences in location and dispersion parameters. (a) Two populations of similar frequency distributions, but different location parameters (μ_2 is larger than μ_1). (b) Two populations with similar frequency distributions and the same location parameter, but different dispersion parameters (σ_2^2 is larger than σ_1^2).

ERRO PADRÃO DA MÉDIA (EP)

Mede a dispersão em relação ao *n* amostral.

$$EP = \frac{s}{\sqrt{n}}$$

Indica que quanto maior o tamanho da amostra (*n*), menor o erro da média.

Erro padrão da média é uma medida de dispersão inferencial.

MEDIDA DE DISPERSÃO RELATIVA → COEFICIENTE DE VARIAÇÃO

Serve para comparar a dispersão entre duas séries de natureza distintas, como diferentes *n*'s, escalas e unidades diferentes.

$$CV = \frac{s}{\overline{X}} * 100$$

CV=2,82/5*100=56,4

Ex. Qual grupo tem maior variação?

Crianças	Adultos
4	66
2	64
6	62
s=1,63	s=1,63
$\overline{x}$ = 4	$\overline{x}$ = 64
CV=40,7%	CV=4,15%

ASSIMETRIA E CURTOSE

ASSIMETRIA: é o grau de desvio ou afastamento da simetria da curva de distribuição de freqüências.

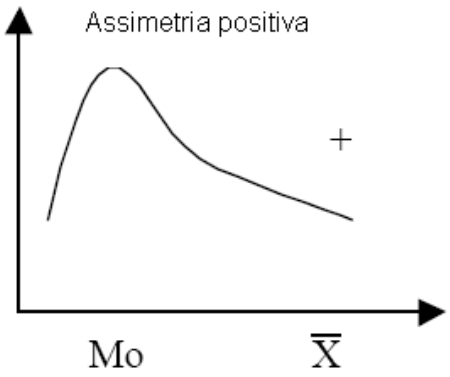

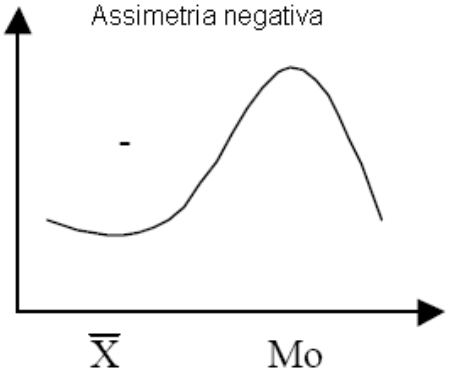
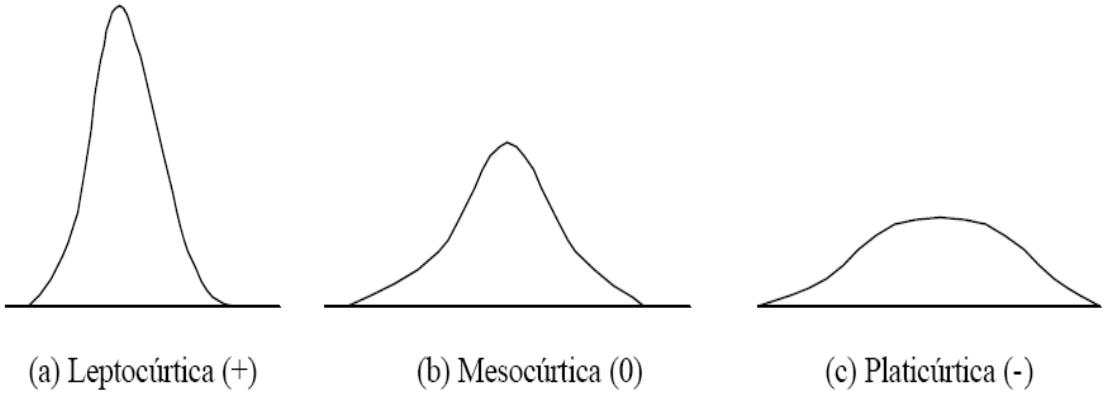
CURTOSE: é o grais de achatamento da curva.